

Pilotage intelligent de la facture d'électricité d'un bâtiment

Laïs Hindeme^a, Zozerigué Traoré^{a, 1}, Benoît Djossou^a, Pacifique Lubungu^a, Eléazar Dègnon Samuel Tognon^a, Emilienne Adangnissode^a

^a Programme d'Introduction à l'Intelligence Artificielle (PIIA), Académie des Mathématiques Appliquées, Cotonou, Bénin.

INFORMATIONS

Mots-clés :

Régression Ridge
Descente de gradient
Conditionnement
Analyse en composantes principales
Plus court chemin

Classification MSC 2020 :
62J07, 65F35, 90C25, 05C85

Encadrement :

Ing. Charbel

Cadre pédagogique :

Projet de Modélisation Mathématique
PIIA, 2^e cohorte
Année 2025–2026

RÉSUMÉ

Contexte. La facture d'électricité d'un immeuble de bureaux augmente sans que le gérant en comprenne les causes ; il ne dispose que de relevés horaires de température, d'occupation et de consommation. **Méthode.** Nous formulons la prédiction comme une régression linéaire pénalisée, dont nous établissons la convexité stricte et dérivons le gradient à la main. Les poids sont estimés à la fois par les équations normales et par descente de gradient. Nous étudions le conditionnement de la matrice des données et montrons que la pénalisation le réduit. La prédiction est ensuite transformée en recommandation par un graphe d'états orienté et sans cycle, dont le chemin de coût minimal fournit un plan de gestion. **Résultats.** Sur des données synthétiques réalistes, les deux estimateurs coïncident (écart de 2×10^{-8}), le conditionnement passe de 15,25 à 8,91, et le plan recommandé réduit la consommation d'environ 18 % à confort égal. **Portée.** L'approche relie de manière cohérente algèbre linéaire, statistique et optimisation, et débouche sur un outil d'aide à la décision simple et vérifiable.

Abstract. The electricity bill of an office building keeps rising without the manager understanding why ; only hourly records of temperature, occupancy and consumption are available. We cast prediction as a penalised linear regression, prove its strict convexity and derive its gradient by hand. Weights are estimated both by the normal equations and by gradient descent. We study the conditioning of the data matrix and show that penalisation reduces it. The prediction is then turned into a recommendation through a directed acyclic state graph, whose minimum-cost path yields a management plan. On realistic synthetic data, both estimators coincide (gap 2×10^{-8}), the conditioning drops from 15,25 to 8,91, and the recommended plan cuts consumption by about 18 % at equal comfort. The approach coherently links linear algebra, statistics and optimisation into a simple, verifiable decision-support tool.

© 2026 Académie des Mathématiques Appliquées. Tous droits réservés.

1. Introduction

Contexte. La maîtrise de la consommation électrique des bâtiments est un enjeu concret de coût et de sobriété énergétique. Un gérant d'immeuble de bureaux à Cotonou fait face à une facture croissante sans en identifier les causes, alors qu'il dispose de relevés horaires simples : température extérieure, nombre d'occupants et consommation mesurée.

État de l'art. Deux familles d'approches se distinguent. Les approches empiriques se contentent d'extrapoler les factures passées, sans modèle explicatif. Les approches statistiques apprennent une relation entre variables et consommation : la régression linéaire pénalisée et son estimation sont traitées dans le cours [1] et, plus en détail pour l'inférence, dans [2]. La transformation d'une prédiction en décision séquentielle relève, elle, des algorithmes de graphes [3].

Verrou scientifique. La littérature pédagogique s'arrête souvent à la prédiction et laisse de côté deux points : la stabilité numérique de l'estimation lorsque les variables sont redondantes, et le passage de la prédiction à une recommandation concrète.

1. Auteur correspondant. Adresse : 01 BP, 2iE, Ouagadougou, Burkina Faso.

Adresses électroniques : zozerigué.traoré@2ie-edu.org (Z. Traoré, auteur correspondant), djossoubenoit94@gmail.com (B. Djossou), degonsamuel008@gmail.com (E. D. S. Tognon).

Question de recherche. Peut-on estimer de façon stable un modèle de consommation à partir de variables corrélées, puis en déduire un plan horaire qui minimise la dépense sous une contrainte de confort ?

Contributions. Nos apports sont les suivants.

1. une formulation du problème comme régression pénalisée, équation (1) ;
2. une preuve de convexité stricte et une dérivation complète du gradient (théorème 7) ;
3. une analyse du conditionnement montrant que la pénalisation le réduit (proposition 5) ;
4. une validation numérique et une recommandation par graphe réduisant la consommation de 18 %.

Plan. La section 2 pose le cadre théorique et les notations. La section 3 décrit la méthodologie. La section 4 présente les résultats, discutés en section 5. La section 6 conclut et ouvre des perspectives.

2. Cadre théorique et notations

2.1 Notations

Les principales notations sont rassemblées dans le tableau 1.

TABLE 1 – Principales notations utilisées dans le rapport.

Symbole	Signification
$X \in \mathbb{R}^{n \times p}$	matrice des données (une ligne par heure)
$y \in \mathbb{R}^n$	vecteur des consommations
$\beta \in \mathbb{R}^p$	vecteur des poids à estimer
$\varepsilon \in \mathbb{R}^n$	bruit aléatoire
$\lambda > 0$	paramètre de pénalisation
Σ	matrice de covariance empirique
κ	nombre de conditionnement
$\nabla J, H$	gradient et hessienne du coût

2.2 Hypothèses de travail

Hypothèse 1 (Modèle linéaire gaussien). La consommation dépend linéairement des variables mesurées, à un bruit près : $y = X\beta + \varepsilon$, avec $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$ et des observations indépendantes.

2.3 Modèle et fonction de coût

Sous l'hypothèse 1, chaque consommation suit une loi gaussienne centrée sur la prédiction $x_i^\top \beta$. La vraisemblance des observations, une fois passée au logarithme, ne dépend des poids que par le terme des écarts au carré. Maximiser la vraisemblance équivaut donc à minimiser $\|X\beta - y\|^2$. Conformément au sujet, nous ajoutons une pénalité de confort, réglée par λ , ce qui donne la fonction de coût

$$J(\beta) = \frac{1}{n} \|X\beta - y\|^2 + \lambda \|\beta\|^2, \quad \lambda > 0. \quad (1)$$

Remarque 2. La contrainte de confort est traitée par pénalisation, et non par les multiplicateurs de Lagrange, afin de rester dans le cadre de la descente de gradient (consigne méthodologique du sujet).

2.4 Représentation algébrique et réduction de dimension

Les échelles des variables étant très différentes, nous centrons et réduisons chaque colonne (standardisation), ce qui rapproche le conditionnement de un [1]. En notant X_c la matrice centrée, la covariance empirique est $\Sigma = \frac{1}{n} X_c^\top X_c$.

Proposition 3. Σ est symétrique et semi-définie positive.

Démonstration. $\Sigma^\top = \frac{1}{n} (X_c^\top X_c)^\top = \frac{1}{n} X_c^\top X_c = \Sigma$. De plus, pour tout z , $z^\top \Sigma z = \frac{1}{n} \|X_c z\|^2 \geq 0$. □

Par le théorème spectral (cours, théorème 2.1), $\Sigma = Q\Lambda Q^\top$ avec Q orthogonale et Λ diagonale : les vecteurs propres sont les axes naturels des données, et les valeurs propres en mesurent la variance.

Diagonalisation détaillée (exemple). Prenons deux variables très corrélées, de matrice de corrélation $R = \begin{pmatrix} 1 & 0,85 \\ 0,85 & 1 \end{pmatrix}$. On résout $\det(R - \lambda I) = 0$, soit $(1 - \lambda)^2 - 0,85^2 = 0$, d'où $\lambda_1 = 1,85$ et $\lambda_2 = 0,15$. Pour λ_1 , le système donne $y = x$, soit l'axe $\frac{1}{\sqrt{2}}(1, 1)$; pour λ_2 , $y = -x$, soit $\frac{1}{\sqrt{2}}(1, -1)$. Leur produit scalaire vaut $\frac{1}{2}(1 - 1) = 0$: ils sont orthogonaux, comme le garantit le théorème spectral. Le premier axe porte $\lambda_1/(\lambda_1 + \lambda_2) = 92,5\%$ de l'information.

Sur nos données. Les deux variables réellement corrélées, l'heure et la température, donnent les valeurs propres 1,88 et 0,13 : le premier axe capte 93,7% de la variance (figure 1). On peut donc réduire la dimension par analyse en composantes principales (ACP) en ne perdant qu'une faible part d'information.




FIGURE 1 – Nuage des deux variables corrélées (heure, température) et ses axes principaux. Le premier axe (en rouge) porte 93,7% de la variance.

2.5 Conditionnement et régularisation

Définition 4 (Conditionnement). Le nombre de conditionnement de $A = \frac{1}{n}X^\top X$ est $\kappa = \lambda_{\max}/\lambda_{\min}$. Proche de un, la surface d'erreur est ronde; grand, c'est un « ravin » qui ralentit la descente de gradient (cours, définition 2.5).

Proposition 5. La pénalisation réduit le conditionnement : $\kappa(\lambda) = \frac{\lambda_{\max} + \lambda}{\lambda_{\min} + \lambda} < \kappa$.

Démonstration. Si $Av = pv$, alors $(A + \lambda I)v = (p + \lambda)v$: les vecteurs propres sont inchangés et chaque valeur propre augmente de λ . Le rapport de la plus grande à la plus petite diminue donc strictement. $\square$

2.6 Analyse statistique : significativité des poids

Une fois les poids estimés, nous vérifions si chacun compte vraiment. Sous l'hypothèse 1, l'estimateur des moindres carrés est sans biais, de variance $\widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}^2(X^\top X)^{-1}$, où $\hat{\sigma}^2 = \frac{1}{n-p} \sum_i (y_i - x_i^\top \hat{\beta})^2$. L'erreur standard $\text{se}(\hat{\beta}_j)$ est la racine du j -ième terme diagonal, et l'intervalle de confiance à 95 % est $\hat{\beta}_j \pm 1,96 \text{se}(\hat{\beta}_j)$. Une variable est significative si son intervalle ne contient pas zéro; les valeurs numériques figurent au tableau 2.

Remarque 6 (Source hors cours). Les intervalles de confiance en régression ne sont pas traités dans le cours; nous suivons [2] (chapitre 3). Une alternative, sans hypothèse sur la loi du bruit, serait le rééchantillonnage (bootstrap).

3. Méthodologie

3.1 Approche retenue

Nous choisissons la régression pénalisée pour sa stabilité face aux variables corrélées, et nous l'estimons de deux façons complémentaires : une formule directe pour la référence, et la descente de gradient vue en cours

pour l'aspect algorithmique. La recommandation est ensuite obtenue par un plus court chemin, méthode simple et bien caractérisée.

3.2 Convexité, gradient et estimation des poids

Théorème 7 (Convexité et solution). *La fonction J de (1) est strictement convexe, et son unique minimiseur est*

$$\hat{\beta} = (X^\top X + n\lambda I)^{-1} X^\top y. \quad (2)$$

Éléments de preuve. La hessienne $H = \frac{2}{n}X^\top X + 2\lambda I$ vérifie $z^\top H z = \frac{2}{n}\|Xz\|^2 + 2\lambda\|z\|^2 > 0$ pour $z \neq 0$: elle est définie positive, donc J est strictement convexe (cours, théorème 1.3). L'annulation du gradient $\nabla J(\beta) = \frac{2}{n}X^\top(X\beta - y) + 2\lambda\beta$ donne (2). La démonstration détaillée figure en annexe A. $\square$

L'alternative à la formule (2) est la descente de gradient (algorithme 1), qui évite l'inversion de matrice, coûteuse et instable en cas de mauvais conditionnement.

Algorithme 1 Descente de gradient à pas constant.

Entrées : données X , cible y , pénalité λ , pas α , tolérance ε

Sorties : poids $\hat{\beta}$

```

1:  $\beta \leftarrow 0$ 
2: tant que  $\|\nabla J(\beta)\| > \varepsilon$  faire
3:    $\beta \leftarrow \beta - \alpha \nabla J(\beta)$ 
4: fin tant que
5: retourner  $\beta$ 

```

3.3 Mise en œuvre numérique

Les expériences sont menées en Python 3, avec NumPy pour le calcul et Matplotlib pour les figures. Le code 1 montre le cœur de l'estimation.

Code 1 – Coût, gradient et descente de gradient.

```

1 def cout(X, y, beta, lam):
2     n = X.shape[0]
3     return (1/n)*np.sum((X @ beta - y)**2) + lam*np.sum(beta**2)
4
5 def gradient(X, y, beta, lam):
6     n = X.shape[0]
7     return (2/n)*X.T @ (X @ beta - y) + 2*lam*beta
8
9 def descente_gradient(X, y, lam, alpha, tol=1e-8):
10    beta = np.zeros(X.shape[1]) # on part de zero
11    while np.linalg.norm(gradient(X, y, beta, lam)) > tol:
12        beta = beta - alpha*gradient(X, y, beta, lam)
13    return beta

```

3.4 Du modèle à la recommandation : graphe d'états

Nous découpons la journée type en heures. À chaque heure, le bâtiment prend un état (mode normal ou mode économie), et la consommation de cet état est *prédite par le modèle* (2). Une arête ne relie que des états successifs dans le temps : le graphe est orienté et sans cycle. Le plan optimal est le chemin de consommation cumulée minimale, obtenu par programmation dynamique (algorithme 2). Le mode économie est interdit aux heures les plus chaudes, pour le confort.

3.5 Protocole d'évaluation

Faute de mesures réelles, nous générons des données synthétiques réalistes (température liée à l'heure, occupation, bruit gaussien), avec des poids connus, afin de pouvoir vérifier que le modèle les retrouve. Nous évaluons quatre points : la concordance entre les deux estimations, l'effet de λ sur le conditionnement, la sensibilité au pas α , et le gain par rapport à une stratégie de référence.

Remarque 8 (Reproductibilité). La graine aléatoire est fixée (`seed = 42`). L'ensemble du code se trouve dans le carnet compagnon (annexe C) et s'exécute de haut en bas.

Algorithme 2 Plus court chemin dans le graphe acyclique par couches.

Entrées : états de chaque heure et leur consommation prédite

Sorties : suite d'états de coût cumulé minimal

- 1: **pour** chaque état de la première heure **faire**
 - 2: $\text{coût}_{\min} \leftarrow \text{sa consommation}$
 - 3: **fin pour**
 - 4: **pour** chaque heure suivante, chaque état **faire**
 - 5: $\text{coût}_{\min} \leftarrow \text{consommation} + \text{meilleur coût de l'heure précédente}$
 - 6: mémoriser l'état précédent choisi
 - 7: **fin pour**
 - 8: remonter le meilleur chemin depuis la dernière heure
-

4. Résultats

4.1 Concordance des deux estimations

La descente de gradient et les équations normales minimisent le même coût convexe : elles doivent coïncider. Le code confirme un écart de 2×10^{-8} , nul en pratique. La figure 2 montre la décroissance régulière du coût au fil des itérations.




FIGURE 2 – Décroissance du coût au fil des itérations de la descente de gradient ($\alpha = 0,1$).

4.2 Significativité des variables

Le tableau 2 donne les poids estimés sans pénalité, leur erreur standard et leur intervalle de confiance à 95 %. Aucun intervalle ne contient zéro : les trois variables sont significatives. De plus, les poids retrouvent les vrais poids ayant servi à générer les données.

TABLE 2 – Poids, erreur standard et intervalle de confiance à 95 % (moindres carrés).


Variable	Poids $\hat{\beta}_j$	Erreur standard	IC à 95 %
Heure	3,94	0,30	[3,36; 4,52]
Température	12,06	0,30	[11,48; 12,63]
Occupants	8,05	0,14	[7,76; 8,33]

4.3 Effet de la régularisation sur le conditionnement

La figure 3 et le tableau 3 montrent la décroissance de κ avec λ , conforme à la proposition 5.

4.4 Sensibilité au pas d'apprentissage

La figure 4 illustre l'effet de α : un petit pas converge lentement, un bon pas converge vite, et un pas trop grand ($\alpha = 1$) fait diverger l'algorithme.

FIGURE 3 – Le conditionnement κ décroît avec la pénalité λ , en accord avec la théorie.TABLE 3 – Conditionnement $\kappa(\lambda)$ mesuré sur les données.

λ	0	0,1	0,5	1,0
$\kappa(\lambda)$	15,25	8,91	3,84	2,58

4.5 Recommandation et gain

Le chemin optimal (figure 5) recommande le mode économie le matin et le soir, et le mode normal au pic de chaleur. Le tableau 4 détaille le plan heure par heure, et le tableau 5 compare notre plan à la stratégie de référence.

TABLE 4 – Plan recommandé heure par heure : mode retenu et consommation prédite.

Heure	8h	10h	12h	14h	16h	18h
Mode	éco.	éco.	normal	normal	éco.	éco.
Consommation (kWh)	20,1	29,6	54,8	64,3	58,1	67,6

Résultat principal. Les deux estimateurs coïncident, la pénalisation réduit le conditionnement conformément à la théorie, et le plan recommandé réduit la consommation d'environ 18 % à confort égal.

5. Discussion

5.1 Interprétation des résultats

La baisse du conditionnement s'explique par le relèvement de la plus petite valeur propre, responsable du ravin. La pénalisation ne limite donc pas seulement l'amplitude des poids : elle stabilise l'apprentissage.

Le tableau 6 illustre le compromis introduit par la pénalité. Sans pénalité, les poids retrouvent presque exactement les vrais ; avec pénalité, ils s'en écartent un peu, ce qui est un biais, mais l'estimation gagne en stabilité. Ce compromis biais contre stabilité est classique et acceptable.

5.2 Comparaison avec la référence pédagogique

Nos résultats sont cohérents avec le cours [1] : l'ordre de grandeur des gains et le comportement de la descente de gradient (convergence, divergence pour un pas trop grand) reproduisent les phénomènes décrits. Les intervalles de confiance, empruntés à [2], confirment que les trois variables sont significatives.

5.3 Limites

- les données sont synthétiques, faute de mesures réelles ;
- le graphe est volontairement grossier, avec peu d'états par heure ;
- le modèle suppose une relation linéaire.




FIGURE 4 – Effet du pas d'apprentissage sur la convergence de la descente de gradient.




FIGURE 5 – Graphe des états et chemin recommandé (en noir) sur une journée type.

5.4 Menaces à la validité

La comparaison repose sur une seule stratégie de référence et un seul jeu de données simulé. La pénalité introduit un biais volontaire sur les poids, échangé contre de la stabilité ; ce compromis doit être gardé à l'esprit lors de l'interprétation.

6. Conclusion et perspectives

Nous avons formulé la prédiction de consommation comme une régression pénalisée (1), prouvé sa convexité stricte et l'existence d'une solution unique (théorème 7), montré que la pénalisation améliore le conditionnement (proposition 5), puis transformé la prédiction en recommandation par un graphe. La validation numérique confirme la théorie et un gain d'environ 18 %.

Perspectives. Trois prolongements se dégagent :

1. l'utilisation de mesures réelles du bâtiment ;
2. un graphe plus fin, avec davantage d'états et d'heures ;
3. un modèle non linéaire pour capturer des effets ignorés par le modèle linéaire.

Contributions des auteurs

Le travail a été partagé dans l'ordre logique du projet. **L. Hindeme** : génération et préparation des données, matrice X . **Z. Traoré** : covariance, corrélation, théorème spectral et ACP. **B. Djossou** : modèle, bruit gaussien, convexité et équations normales. **P. Lubungu** : dérivation du gradient, descente de gradient, sensibilité au pas. **E. D. S. Tognon** : conditionnement et régularisation. **E. Adangnissode** : analyse statistique, graphe et comparaison de référence. L'assemblage et les relectures ont été faits en commun.

Remerciements

Les auteurs remercient Ing. Charbel pour son encadrement, ainsi que l'Académie des Mathématiques Appliquées pour le cadre pédagogique du programme PIIA.

TABLE 5 – Consommation cumulée d'une journée type selon la stratégie.

Stratégie	Consommation (kWh)	Écart
Référence (mode normal toute la journée)	357	—
Recommandée (chemin optimal)	294	−63 kWh

TABLE 6 – Poids vrais, sans pénalité (moindres carrés) et avec pénalité (Ridge, $\lambda = 0,1$).

Variable	Vrai poids	Sans pénalité	Avec pénalité
Heure	4,00	3,94	5,23
Température	12,00	12,05	9,87
Occupants	8,00	8,05	7,28

Déclaration d'originalité

Ce travail est original et réalisé par les auteurs. Toute source externe (texte, résultat, code) est citée explicitement. Les auteurs ont utilisé un outil d'assistance par intelligence artificielle pour la mise en forme du document et l'aide à la rédaction; l'ensemble des choix de modélisation, des démonstrations, du code et des analyses a été conçu, vérifié et validé par les auteurs.

A. Démonstration complète

Règles de dérivation. Pour a constant, $\nabla_{\beta}(\beta^{\top}a) = a$; pour A symétrique, $\nabla_{\beta}(\beta^{\top}A\beta) = 2A\beta$.

Gradient. En développant $J(\beta) = \frac{1}{n}(y^{\top}y - 2\beta^{\top}X^{\top}y + \beta^{\top}X^{\top}X\beta) + \lambda\beta^{\top}\beta$ et en dérivant terme à terme,

$$\nabla J(\beta) = \frac{2}{n}X^{\top}X\beta - \frac{2}{n}X^{\top}y + 2\lambda\beta = \frac{2}{n}X^{\top}(X\beta - y) + 2\lambda\beta.$$

Hessienne et convexité. $H = \frac{2}{n}X^{\top}X + 2\lambda I$, et $z^{\top}Hz = \frac{2}{n}\|Xz\|^2 + 2\lambda\|z\|^2 > 0$ pour $z \neq 0$, donc J est strictement convexe.

Solution. $\nabla J(\beta) = 0 \Rightarrow (X^{\top}X + n\lambda I)\beta = X^{\top}y$. La matrice $X^{\top}X + n\lambda I$ a pour valeurs propres $\mu + n\lambda > 0$ (car $\mu \geq 0$ et $\lambda > 0$), donc elle est inversible et $\hat{\beta} = (X^{\top}X + n\lambda I)^{-1}X^{\top}y$.

B. Exemple numérique vérifié

Pour $X = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$, $y = (1, 2, 2)^{\top}$, $n = 3$, $\lambda = 0,5$, on obtient $X^{\top}X + n\lambda I = \begin{pmatrix} 3,5 & 1 \\ 1 & 3,5 \end{pmatrix}$, $X^{\top}y = (3, 4)^{\top}$,

d'où $\hat{\beta} = (0,5778, 0,9778)^{\top}$. On vérifie que $\nabla J(\hat{\beta}) = 0$.

C. Code source

Le carnet compagnon (notebook Python) contient l'intégralité du code, organisé dans le même ordre que ce rapport, et s'exécute de haut en bas. Il est fourni séparément avec ce rapport.

Références

- [1] C. Mamlankou, *Mathématiques fondamentales pour l'IA*, Académie des Mathématiques Appliquées, PIIA cohorte 2. Chapitres 1 (calcul numérique) et 2 (algèbre linéaire).
- [2] G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, Springer, chapitre 3. <https://www.statlearning.com>
- [3] T. Cormen, C. Leiserson, R. Rivest, C. Stein, *Introduction to Algorithms*, MIT Press. <https://mitpress.mit.edu/books/introduction-algorithms-third-edition>